



**CENTRO UNIVERSITÁRIO CHRISTUS
PÓS-GRADUAÇÃO (*LATO SENSU*) UNICHRISTUS**

**Francisco Renato Gomes - POS19100137
Diego Herbestor Sancho de Oliveira - POS19100119
Roberto Dennys M. Nogueira - POS19100120**

**Projeto de Machine Learning: Modelo de árvore de
decisão para análise histórica de dados na criação de
uma ferramenta preditiva e estratégica.**

PROFESSOR: FELIPE VIANA

**FORTALEZA
2020**

Relatório do projeto de ciência de dados com Machine Learning, utilizando o modelo de árvore de decisão em um conjunto de dados histórico como ferramenta preditiva e estratégica de renovação de estoque.

Este arquivo contém informações sobre o projeto que está sendo executado, nesse caso, auxiliar na tomada de decisão utilizando o modelo de árvore de decisão e um conjunto de dados histórico como ferramenta preditiva e estratégica de renovação de estoque.

1. Entendimento comercial

- NOTA: Este é um exemplo de tutorial, portanto, o escopo, o plano etc. não correspondem necessariamente a um projeto real de ciência de dados que aborda uma questão comercial específica. Em um projeto real, é provável que a seção de definição do problema, escopo, plano e pessoal seja muito mais detalhada.

Definição de problema

A finalidade deste projeto é auxiliar na decisão de compra ou não de um determinado produto pra renovação de estoque. Neste cenário, o analista de compra precisa analisar e decidir quais produtos comprar. Levando em consideração que os mesmos são importados da china, e levam até 3 meses para chegar na empresa, os custos com importação, ele precisar saber se os produtos com estoques baixos são de fato indicado para importação.

Para isso, a empresa dispõe de uma base histórica de mais de 10 anos com os dados de compra e venda por produto. Nesta base, features como quantidade vendida, valor unitário, custo unitário, estoque e margem de contribuição, podem auxiliar na previsão de venda e lucro do produto.

Com esse objetivo em mente, utilizaremos algoritmos de machine learning, data analysis e estatística que estão armazenados nas diversas bibliotecas do Python. Escolhemos a Scikit Learn, da qual importaremos o estimador DecisionTreeClassifier, que é um modelo de árvore de decisão. Ele é um tipo de algoritmo de aprendizagem supervisionada, muito utilizada em problemas de classificação, e será muito útil para analisar o histórico de compra e vendas dos produtos no treinamento do modelo.

Escopo

- A Idealização do projeto se deu através da análise das necessidades estratégicas da empresa, utilizando a modelagem de painéis como Business Model Canvas;
- O escopo deste exemplo é criar um modelo de aprendizado de máquina de classificação binária que resolva o problema descrito a cima;
- Utilizaremos algoritmos de machine learning, data analysis e estatística que estão armazenados nas diversas bibliotecas do Python. Escolhemos a Scikit Learn, da qual importaremos o estimador DecisionTreeClassifier, que é um modelo de árvore de decisão;
- Operacionalizamos a solução para uso do analista de compras, para que o mesmo tenha controle eficiente do estoque e possa tomar melhor decisão na hora de efetuar a compra de materiais.

Plano

Seguimos o modelo de árvore de decisão e organizamos a documentação, o código e a base de dados de forma alinhada com a estratégia da empresa. A documentação sobre o trabalho e as descobertas em cada um dos estágios do ciclo de vida está incluída abaixo. O código foi escrito em python e disponibilizamos para análise a base de dados histórica com 12 meses.

Equipe Pessoal

O projeto é executado por três cientistas de dados, cada um possui um papel fundamental para a realização do projeto, um fica responsável pela documentação, outro pela implementação e desenvolvimento do projeto e outro para testar e corrigir as falhas identificadas.

- NOTA: Em um projeto do cliente, pessoal adicional, tanto de uma equipe de ciência de dados quanto da organização do cliente, pode estar envolvido.

2. Aquisição e entendimento de dados

Dados não tratados

O conjunto de dados utilizados no projeto tem origem do sistema de gestão da empresa, contendo um histórico de mais de 10 anos. Para o desenvolvimento e testes, utilizamos uma base de dados reduzida ao período de um ano.

Os dados são extraídos diretamente do SGBD Relacional Microsoft SQL Server, através de um script e salvos em uma instância online do MySQL Server, tornando possível efetuar a conexão com os mesmos de forma remota.

O script de exportação foi elaborado para enviar apenas as informações elegidas como influenciadoras no processo decisório e estarão disponíveis por tempo indeterminado na instância do MySQL. Disponibilizamos também em formato CSV, em um volume menor para permitir testes e execução do código Python desenvolvido.

Esses dados podem ser encontrado em: <https://github.com/fcorenato/mlpreditivo>

Há um total de 16.458 instâncias (antes de qualquer filtragem), contendo dados de natureza contínua e discreta.

CARACTERÍSTICAS: código, número_do_pedido, data_emissão, mês, ano, nome_do_cliente, tipo_do_cliente, produto, quantidade_vendida, preço_unitário, total, custo_unitário, margem, estoque, compra.

Exploração de dados

A exploração dos dados é realizada usando as seguintes bibliotecas do Python:

- NumPy que suporta arrays e matrizes multidimensionais, possuindo uma larga coleção de funções matemáticas para trabalhar com estas estruturas.
- Pandas que é uma biblioteca de software criada para a linguagem Python para manipulação e análise de dados. Em particular, oferece estruturas e operações para manipular tabelas numéricas e séries temporais.
- Matplotlib é uma biblioteca de softwares para criação de gráficos e visualizações de dados em geral.
- Seaborn que atua em cima do matplotlib e ajuda a melhorar o visual dos gráficos, dando uma aparência mais bem acabada.

3. Modelagem

Engenharia de Recursos

Limpeza de dados: removendo colunas e linhas

Antes da engenharia de recursos, analisamos os dados afim de identificar colunas com valores nulos ou inválidos. Utilizando o Seaborn, criamos um gráfico de temperatura que possibilitou identificar a ausência de dados na coluna "número_do_pedido". Removemos esta coluna, já que a mesma não é relevante.

Em análises posteriores também decidimos remover as seguintes colunas: "cód.", "data_emissão", "nome_cliente".

Recursos categóricos de codificação one-hot

As features "tipo_de_cliente" e "compras" foram codificados utilizando a técnica one-hot code, afim de preparar os dados para treinamento do modelo.

Salvando conjuntos de dados processados para entrada de modelagem

Os conjuntos de dados de treinamento e teste, foram selecionados e salvos em sub-datasets para entrada na modelagem (dados de treinamento) e avaliação ou implantação do modelo (dados de teste).

Treinamento de modelagem

Criamos o modelo de teste e através da função FIT, utilizando 70% para treinamento e 30% para teste.

Avaliação do modelo

A precisão do modelo com o conjunto de dados de teste se mostrou bastante eficiente, conforme os resultados abaixo:

```
: print(classification_report(y_test,predictions))
```

	precision	recall	f1-score	support
0	0.99	0.99	0.99	248
1	0.99	1.00	1.00	599
micro avg	0.99	0.99	0.99	847
macro avg	0.99	0.99	0.99	847
weighted avg	0.99	0.99	0.99	847

Figura 1: Precisão do modelo

Plotamos a matriz de confusão, para termos uma visão gráfica, constatando o resultado obtido pelo modelo:

```
plot_confusion_matrix(cnf_matrix, classes=['Compra', 'NaoCompra'],  
                      title='Confusion matrix, without normalization')
```

Confusion matrix, without normalization

```
[[245  3]  
 [ 2 597]]
```




Figura 2: Matriz de Confusão

Ainda foi possível identificar as correlações mais fortes entre as features:




Figura 3: Correlação Features

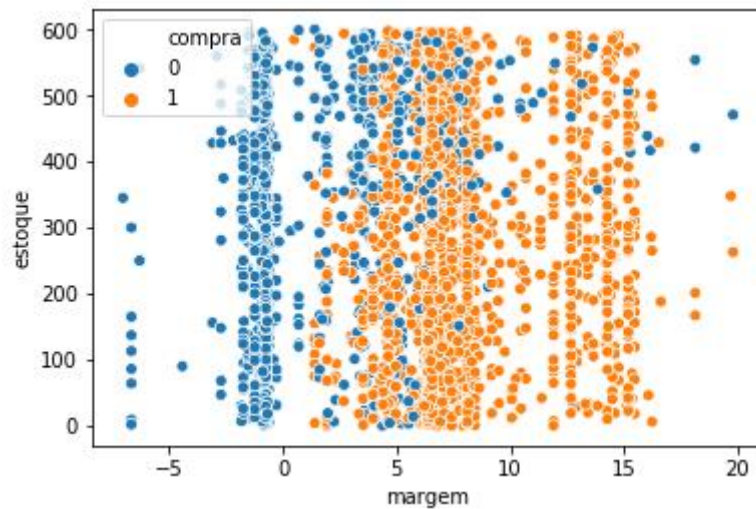


Figura 4: Correlação Features

4. Implantação

Arquitetura, Ambientes e Execução de Código

Neste exemplo, executamos código apenas no ambiente de computação local utilizando o Jupyter notebook.

Repositório de Controle de Versão

Foi criado um repositório no GitHub para controlar o conteúdo e versionamento deste projeto.

Execução de código

Referências

- [Repositório do Projeto no GitHub](#)